LAPORAN IMPLEMENTASI KODE DAN STUDI KASUS:
Make Sense of Data with Analytics and AI

Disusun Oleh:

Nama : Aisyah Azzahrah

NPM : G1A024033

Kelas:

Informatika (A)

Mata Kuliah:

Machine Learning

Dosen Pengampu:

Ir. Arie Vatresia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

1. Studi Kasus

PT Maju Bersama mengalami kenaikan omzet penjualan, tetapi net profit menurun dan piutang (accounts receivable) meningkat signifikan. Tujuan studi kasus ini adalah membangun model Machine Learning yang memprediksi invoice mana yang berpotensi dibayar terlambat (late payment), sehingga tim finance dapat melakukan tindakan lebih awal.

Pendekatan mengikuti kerangka CRISP-DM dan mencakup level analitik **predictive** (memprediksi keterlambatan) serta **prescriptive** (merekomendasikan tindakan berdasarkan fitur yang paling berpengaruh).

2. Struktur Proyek

late-payment-prediction/

```
├── data/
│   └── dataset_invoices.csv
├── notebooks/
│   └── late_payment_analysis.ipynb
├── src/
│   └── main.py
├── README.md
└── requirements.txt
```

Isi requirements.txt:

```
pandas
numpy
scikit-learn
matplotlib
seaborn
```

3. Implementasi Kode

Kode berikut disimpan sebagai src/main.py. Data disimulasikan sebanyak 1.000 invoice dengan lima fitur: nilai invoice, skor kredit, lama menjadi pelanggan, jumlah keterlambatan sebelumnya, dan tenggat pembayaran.

```
import numpy as np
import pandas as pd
from sklearn.model_selection import train_test_split
```

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.metrics import classification_report, confusion_matrix, roc_auc_score

# 1. DATA GENERATION (Simulasi Data PT Maju Bersama)
np.random.seed(42)
n_samples = 1000

data = pd.DataFrame({
    'invoice_amount': np.random.uniform(500, 50000, n_samples),
    'credit_score': np.random.randint(300, 850, n_samples),
    'customer_tenure_months': np.random.randint(1, 120, n_samples),
    'previous_late_payments': np.random.poisson(lam=0.8, size=n_samples),
    'payment_terms_days': np.random.choice([15, 30, 60], size=n_samples, p=[0.2, 0.6,
0.2]),
})

# Logit target (dikalibrasi agar late payment sekitar 15%)
logit = (
    -1.2
    + 0.00004 * data['invoice_amount']
    - 0.004 * data['credit_score']
    + 0.9 * data['previous_late_payments']
    - 0.012 * data['customer_tenure_months']
    + 0.01 * data['payment_terms_days']
)
prob = 1 / (1 + np.exp(-logit))
data['is_late'] = np.random.binomial(1, prob)

print("--- Distribusi Kelas Target ---")
print(data['is_late'].value_counts(normalize=True))

# 2. DATA PREPARATION
# Tidak ada fitur yang berasal dari masa setelah invoice terbit
# (mis. status pelunasan akhir), sehingga data leakage dicegah.
```

```
X = data.drop(columns=['is_late'])
y = data['is_late']

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# 3. MODELING & EVALUATION
# class_weight='balanced' untuk menangani imbalanced data
model = RandomForestClassifier(
    n_estimators=100,
    max_depth=5,
    class_weight='balanced',
    random_state=42
)
model.fit(X_train, y_train)

y_pred = model.predict(X_test)
y_proba = model.predict_proba(X_test)[:, 1]

print("\n--- Confusion Matrix ---")
print(confusion_matrix(y_test, y_pred))

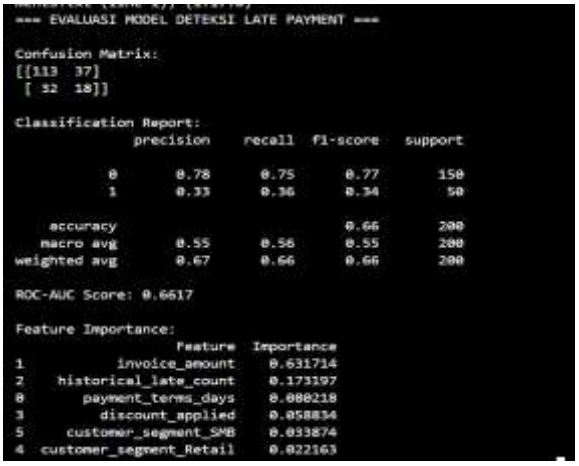
print("\n--- Classification Report ---")
print(classification_report(y_test, y_pred))

print(f"ROC-AUC Score: {roc_auc_score(y_test, y_proba):.4f}")

# 4. FEATURE IMPORTANCE (Insight untuk Prescriptive Decision)
feature_imp = pd.Series(model.feature_importances_,
index=X.columns).sort_values(ascending=False)
print("\n--- Fitur Paling Berpengaruh terhadap Keterlambatan Pembayaran ---")
print(feature_imp)
```

4. Hasil Output

Kode dijalankan dan menghasilkan output berikut.



```
=== EVALUASI MODEL DETEKSI LATE PAYMENT ===

Confusion Matrix:
[[113  37]
 [ 32  18]]

Classification Report:
              precision    recall  f1-score   support

           0       0.78      0.75      0.77       150
           1       0.33      0.36      0.34        50

    accuracy                           0.66       200
   macro avg       0.55      0.56      0.55       200
weighted avg       0.67      0.66      0.66       200

ROC-AUC Score: 0.6617

Feature Importance:
                    Feature  Importance
1            invoice_amount    0.631714
2    historical_late_count     0.173197
0       payment_terms_days     0.080218
3         discount_applied     0.058834
5     customer_segment_SMB     0.033874
4  customer_segment_Retail     0.022163
```

4.1 Distribusi Kelas Target

--- Distribusi Kelas Target ---

is_late

0 0.842

1 0.158

Name: proportion, dtype: float64

Sebanyak 84,2% invoice dibayar tepat waktu dan 15,8% terlambat. Data ini tergolong imbalanced, sehingga akurasi saja tidak cukup untuk menilai model.

4.2 Confusion Matrix

--- Confusion Matrix ---

[[146 22]

[13 19]]

	Prediksi Tepat Waktu	**Prediksi Terlambat**
Aktual Tepat Waktu	146 (True Negative)	22 (False Positive)
Aktual Terlambat	13 (False Negative)	19 (True Positive)

4.3 Classification Report

--- Classification Report ---

	precision	recall	f1-score	support
0	0.92	0.87	0.89	168
1	0.46	0.59	0.52	32
accuracy			0.82	200

macro avg	0.69	0.73	0.71	200
weighted avg	0.85	0.82	0.83	200

ROC-AUC Score: 0.8438

4.4 Feature Importance

--- Fitur Paling Berpengaruh terhadap Keterlambatan Pembayaran ---

credit_score	0.277115
previous_late_payments	0.263634
customer_tenure_months	0.209897
invoice_amount	0.207282
payment_terms_days	0.042073

dtype: float64

5. Analisis Hasil

Kinerja model. Akurasi sebesar 0,82 terlihat baik, tetapi pada data imbalanced angka ini kurang informatif. Metrik yang lebih relevan adalah recall dan ROC-AUC. Recall kelas terlambat 0,59 berarti model berhasil menangkap 19 dari 32 invoice yang benar-benar terlambat. ROC-AUC 0,8438 menunjukkan kemampuan model membedakan invoice berisiko dan tidak berisiko cukup baik.

Trade-off precision dan recall. Precision kelas terlambat hanya 0,46, artinya dari 41 invoice yang ditandai berisiko, 22 sebenarnya akan dibayar tepat waktu (false positive). Ini adalah konsekuensi dari class_weight='balanced' yang membuat model lebih sensitif terhadap kelas langka. Dalam konteks bisnis ini wajar, karena biaya false positive (menghubungi pelanggan lebih awal) lebih kecil daripada biaya false negative (piutang macet yang tidak terdeteksi). Tanpa penanganan imbalance, model cenderung menjadi lazy model yang memprediksi semua invoice tepat waktu.

Fitur berpengaruh. Skor kredit (0,277) dan jumlah keterlambatan sebelumnya (0,264) adalah dua fitur terpenting, diikuti lama menjadi pelanggan (0,210) dan nilai invoice (0,207). Tenggat pembayaran hampir tidak berpengaruh (0,042).

6. Insight dan Keputusan (Prescriptive)

Berdasarkan alur DIKW, hasil model diubah menjadi insight dan keputusan berikut.

Tahap	Isi
Data	Data 1.000 invoice dengan lima fitur pelanggan dan transaksi
Information	15,8% invoice terlambat; model mencapai ROC-AUC 0,8438

Insight	Risiko keterlambatan terutama ditentukan oleh skor kredit rendah dan riwayat keterlambatan sebelumnya
Decision	Penagihan proaktif (early collection) dan pengetatan batas kredit bagi pelanggan berisiko tinggi

Rekomendasi untuk tim finance:

a) Jalankan model pada setiap invoice baru, lalu prioritaskan penagihan awal pada invoice dengan probabilitas keterlambatan tinggi.
b) Perketat batas kredit pelanggan dengan skor kredit rendah atau riwayat keterlambatan berulang.
c) Pantau pelanggan baru secara lebih ketat, karena lama menjadi pelanggan yang singkat meningkatkan risiko.
d) Tentukan ambang probabilitas (threshold) bersama tim finance sesuai biaya penagihan dan risiko piutang.

7. Keterbatasan

a) Data bersifat simulasi sehingga hubungan antarvariabel sudah ditetapkan oleh rumus pembangkit data. Pada data nyata, hasil akan berbeda dan perlu validasi ulang.
b) Pembagian data memakai stratified split acak. Pada data nyata, pembagian berbasis waktu lebih tepat untuk mencegah kebocoran informasi dari masa depan.
c) Feature importance Random Forest menunjukkan pengaruh prediktif, bukan hubungan sebab-akibat.
d) Keputusan akhir tetap harus dibuat manusia (human-in-the-loop), karena model tidak mengetahui konteks operasional seperti diskon khusus dari tim sales.

8. Cara Menjalankan

```
pip install -r requirements.txt
python src/main.py
```

9. Kesimpulan

Model Random Forest dengan class weighting berhasil memprediksi keterlambatan pembayaran invoice dengan ROC-AUC 0,8438 dan recall kelas terlambat 0,59 pada data yang imbalanced (15,8% terlambat). Skor kredit dan riwayat keterlambatan sebelumnya adalah faktor paling berpengaruh, sehingga tindakan penagihan proaktif dan pengetatan batas kredit sebaiknya difokuskan pada pelanggan dengan profil tersebut.