LAPORAN IMPLEMENTASI KODE DAN STUDI KASUS:
Attributing Direct Drivers to Deforestation Alerts with Satellite Imagery and AI

Disusun Oleh:

Nama : Aisyah Azzahrah

NPM : G1A024033

Kelas:

Informatika (A)

Mata Kuliah:

Machine Learning

Dosen Pengampu:

Ir. Arie Vatresia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNIK

UNIVERSITAS BENGKULU

2026

A. Studi Kasus

Studi kasus ini mensimulasikan tahap **klasifikasi pemicu** dalam alur kerja atribusi pemicu deforestasi berbasis citra satelit. Setiap peringatan deforestasi direpresentasikan oleh lima fitur hasil ekstraksi citra satelit, lalu model Random Forest memprediksi pemicunya.

1. Fitur Input

Fitur	Penjelasan
Delta_NDVI	Perubahan indeks vegetasi (NDVI) sebelum dan sesudah kejadian; semakin negatif, semakin besar kehilangan vegetasi
Delta_NBR	Perubahan Normalized Burn Ratio; indikator sensitif terhadap area terbakar
Patch_Size_Ha	Luas area terdampak dalam hektare
Distance_to_Road_km	Jarak area ke jalan terdekat
Elevation_m	Ketinggian lokasi dari permukaan laut

2. Kelas Target

Kode	Kelas	Aturan pembentukan label pada simulasi
0	Pertanian / Perkebunan skala kecil	Luas < 3 ha dan jarak jalan < 2 km, atau kondisi default
1	Logging (penebangan komersial)	Luas ≥ 5 ha dan jarak jalan ≥ 2 km (jika tidak masuk aturan kebakaran)
2	Kebakaran hutan	Luas ≥ 3 ha dan Delta_NBR < -0,4

Aturan pada tabel di atas dipakai untuk membangkitkan label data simulasi, dengan urutan prioritas pertanian, kebakaran, lalu logging.

B. Implementasi Kode

Implementasi menggunakan Python dengan pustaka NumPy, pandas, dan scikit-learn. Alurnya: membangkitkan data simulasi 300 sampel, membagi data latih 75% dan data uji 25% secara *stratified*, melatih Random Forest dengan 100 pohon, mengevaluasi model, menampilkan *feature importance*, lalu memprediksi satu peringatan baru.

```
import os


import numpy as np
import pandas as pd
from sklearn.ensemble import RandomForestClassifier
```

```
from sklearn.metrics import accuracy_score, classification_report, confusion_matrix
from sklearn.model_selection import train_test_split

FITUR = ["Delta_NDVI", "Delta_NBR", "Patch_Size_Ha", "Distance_to_Road_km", "Elevation_m"]
NAMA_KELAS = ["Pertanian", "Logging", "Kebakaran"]

# 1. Simulasi dataset fitur ekstraksi citra satelit
np.random.seed(42)
n_samples = 300

delta_ndvi = np.random.uniform(-0.8, -0.1, n_samples)
delta_nbr = np.random.uniform(-0.7, -0.2, n_samples)
patch_size = np.random.exponential(scale=5.0, size=n_samples)
dist_road = np.random.exponential(scale=2.0, size=n_samples)
elevation = np.random.uniform(50, 1200, n_samples)

X = pd.DataFrame(
    {
        "Delta_NDVI": delta_ndvi,
        "Delta_NBR": delta_nbr,
        "Patch_Size_Ha": patch_size,
        "Distance_to_Road_km": dist_road,
        "Elevation_m": elevation,
    }
)

# Label target pemicu deforestasi:
# 0 = Pertanian/Perkebunan skala kecil, 1 = Penebangan komersial, 2 = Kebakaran hutan
conditions = [
    (patch_size < 3) & (dist_road < 2),
    (patch_size >= 3) & (delta_nbr < -0.4),
    (patch_size >= 5) & (dist_road >= 2),
```

```
]
choices = [0, 2, 1]
y = pd.Series(np.select(conditions, choices, default=0), name="Pemicu")

os.makedirs("data", exist_ok=True)
pd.concat([X, y], axis=1).to_csv("data/data_deforestasi.csv", index=False)

print("Jumlah sampel per kelas:")
print(y.map(dict(enumerate(NAMA_KELAS))).value_counts().to_string())

# 2. Bagi data latih dan data uji (stratify agar semua kelas ada di data uji)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42, stratify=y
)

# 3. Latih model Random Forest
rf_model = RandomForestClassifier(n_estimators=100, random_state=42)
rf_model.fit(X_train, y_train)

# 4. Evaluasi model
y_pred = rf_model.predict(X_test)

print("\n--- HASIL EVALUASI MODEL ---")
print(f"Akurasi Model: {accuracy_score(y_test, y_pred) * 100:.1f}%")
print("\nConfusion Matrix:")
print(confusion_matrix(y_test, y_pred, labels=[0, 1, 2]))
print("\nLaporan Klasifikasi:")
print(
    classification_report(
        y_test,
        y_pred,
        labels=[0, 1, 2],
        target_names=NAMA_KELAS,
        zero_division=0,
```

```
    )
)

# 5. Feature importance
importance = pd.DataFrame(
    {"Fitur": FITUR, "Importance": rf_model.feature_importances_}
).sort_values("Importance", ascending=False)
print("Feature Importance:")
print(importance.to_string(index=False))

# 6. Prediksi untuk sampel peringatan deforestasi baru
sampel_baru = pd.DataFrame([[-0.65, -0.55, 4.2, 1.5, 300.0]], columns=FITUR)
prediksi = rf_model.predict(sampel_baru)

nama_pemicu = ["Pertanian / Perkebunan", "Penebangan Komersial", "Kebakaran Hutan"]
print(f"\nHasil Prediksi Pemicu untuk Alert Baru: {nama_pemicu[prediksi[0]]}")
```

1. Penjelasan Tiap Tahap

1. **Simulasi data:** lima fitur dibangkitkan dengan `np.random` (seed 42 agar hasil dapat direproduksi). Luas area dan jarak ke jalan memakai distribusi eksponensial karena pada kenyataannya sebagian besar area kecil dan dekat jalan, sedangkan area besar dan jauh jarang terjadi.
2. **Pembentukan label:** `np.select` memberi label berdasarkan aturan pada tabel 1.2. Data disimpan ke `data/data_deforestasi.csv`.
3. **Pembagian data:** 75% latih dan 25% uji (75 sampel). Parameter `stratify=y` menjaga proporsi kelas di kedua bagian, sehingga kelas langka seperti Logging tetap muncul di data uji.
4. **Pelatihan:** `RandomForestClassifier` dengan 100 pohon keputusan, prediksi akhir berdasarkan suara terbanyak.
5. **Evaluasi:** akurasi, *confusion matrix*, serta *classification report* (precision, recall, F1-score).
6. **Feature importance:** mengukur kontribusi tiap fitur dalam mengurangi ketidakmurnian (*impurity*) pada seluruh pohon.

7. **Prediksi baru:** satu peringatan dengan Delta_NDVI -0,65, Delta_NBR -0,55, luas 4,2 ha, jarak jalan 1,5 km, dan ketinggian 300 m.

C. Hasil Eksekusi

1. Distribusi Kelas dan Evaluasi Model

```
PS C:\Users\Aisa Azahra\tugas-machine-learning\06-deforestasi-rf> python src/defo
restasi_rf.py
Jumlah sampel per kelas:
Pemicu
Pertanian    204
Kebakaran     81
Logging       15

--- HASIL EVALUASI MODEL ---
Akurasi Model: 98.7%

Confusion Matrix:
[[51  0  0]
 [ 0  4  0]
 [ 1  0 19]]
```

2. Laporan Klasifikasi dan Feature Importance

```
Laporan Klasifikasi:
              precision    recall  f1-score   support

   Pertanian       0.98      1.00      0.99        51
     Logging       1.00      1.00      1.00         4
   Kebakaran       1.00      0.95      0.97        20

    accuracy                           0.99        75
   macro avg       0.99      0.98      0.99        75
weighted avg       0.99      0.99      0.99        75

Feature Importance:
              Fitur  Importance
      Patch_Size_Ha    0.488112
          Delta_NBR    0.320208
Distance_to_Road_km    0.104876
         Delta_NDVI    0.044931
        Elevation_m    0.041872

Hasil Prediksi Pemicu untuk Alert Baru: Kebakaran Hutan
```

D. Analisis Hasil

1. Distribusi Kelas

Dari 300 sampel, kelas Pertanian mendominasi (204 sampel, 68%), diikuti Kebakaran (81 sampel, 27%) dan Logging (15 sampel, 5%). Data ini tidak seimbang (*imbalanced*), mirip kondisi nyata di mana kategori pemicu tertentu lebih jarang terjadi.

2. Akurasi dan Confusion Matrix

Model mencapai akurasi **98,7%**, yakni 74 dari 75 sampel uji diprediksi benar. Baris pada confusion matrix adalah kelas sebenarnya dan kolom adalah kelas prediksi:

a) Seluruh 51 sampel Pertanian dan 4 sampel Logging diprediksi benar.
b) Dari 20 sampel Kebakaran, 19 benar dan **1 salah diprediksi sebagai Pertanian**. Ini satu-satunya kesalahan model.

3. Precision, Recall, dan F1-Score

a) **Pertanian:** precision 0,98 karena satu sampel Kebakaran masuk ke prediksi kelas ini (51 dari 52 prediksi benar); recall 1,00.
b) **Logging:** precision, recall, dan F1 sempurna (1,00), tetapi hanya berdasar 4 sampel uji sehingga kurang dapat diandalkan.
c) **Kebakaran:** precision 1,00 (tidak ada kesalahan alarm), recall 0,95 (satu kejadian kebakaran terlewat).

Dalam konteks pemantauan hutan, recall kelas Kebakaran perlu mendapat perhatian khusus karena kejadian yang terlewat berarti respons terlambat.

4. Feature Importance

Patch_Size_Ha (0,488) dan Delta_NBR (0,320) adalah dua fitur paling berpengaruh, disusul Distance_to_Road_km (0,105). Delta_NDVI (0,045) dan Elevation_m (0,042) hampir tidak berkontribusi. Pola ini sejalan dengan aturan pembentukan label: luas area, Delta_NBR, dan jarak jalan memang digunakan sebagai syarat, sedangkan Delta_NDVI dan Elevation dibangkitkan acak tanpa hubungan dengan label.

5. Prediksi Alert Baru

Sampel baru (luas 4,2 ha, Delta_NBR -0,55, jarak jalan 1,5 km) diprediksi sebagai Kebakaran Hutan. Hasil ini masuk akal: area cukup luas dengan penurunan NBR yang tajam adalah ciri area terbakar.

E. Keterbatasan

1. **Data simulasi dan label dibuat dari aturan.** Karena label dihasilkan langsung dari fitur melalui aturan if-then, Random Forest pada dasarnya hanya mempelajari kembali aturan tersebut. Akurasi 98,7% karenanya menunjukkan bahwa algoritma mampu menangkap pola yang jelas, **bukan** bukti bahwa model akan seakurat itu pada data satelit nyata.
2. **Data uji kecil dan kelas Logging langka.** Hanya 4 sampel Logging di data uji, sehingga skor sempurna pada kelas ini tidak stabil.

3. **Fitur sederhana.** Data nyata memerlukan fitur deret waktu, tekstur, dan kombinasi citra optik dengan radar (SAR) untuk mengatasi tutupan awan, sebagaimana dibahas pada kuliah tamu.
4. **Label lapangan.** Pada praktiknya label pemicu harus divalidasi di tingkat tapak, yang datanya terbatas.
5. **Generalisasi wilayah.** Model belum diuji pada wilayah lain, sehingga kebutuhan *transfer learning* belum terjawab.
6. **Hanya satu pembagian data.** Validasi silang (*cross-validation*) belum dilakukan untuk menilai kestabilan hasil.

F. Kesimpulan

Bart menunjukkan bahwa peringatan deforestasi berbasis satelit akan jauh lebih berguna bila dilengkapi atribusi pemicu langsung secara otomatis. Pada implementasi ini, Random Forest berhasil mengklasifikasikan tiga kelas pemicu (Pertanian, Logging, Kebakaran) dengan akurasi 98,7% pada data simulasi, dengan Patch_Size_Ha dan Delta_NBR sebagai fitur paling berpengaruh, dan memprediksi alert baru sebagai Kebakaran Hutan. Meskipun demikian, hasil tersebut terutama menggambarkan alur kerja klasifikasi, sedangkan penerapan nyata masih membutuhkan data satelit sungguhan, label lapangan yang valid, serta evaluasi yang lebih ketat.